

## ④ 正則化

... グリーン関数がローバス（高精度では条件数が大きい）の場合、正則化する



(イズの高周波部分をあさる)

正則化

## ⑤ 打切り特異値分解

Truncated SVD

$$\text{推定解} : \hat{s} = G^+ d = \sum_{k=1}^R \frac{w_k^\top d}{\lambda_k} u_k$$

(=おいたり小さい特異値に対する除算をやめ、 $T < R$

とく、わざわざ)

$$\hat{s}_T = G_T^+ d = \sum_{k=1}^T \frac{w_k^\top d}{\lambda_k} u_k$$

## • 打切り次数 T の決定

解のなれどまで - 正確さのトレードオフ

$$\frac{\|s\|}{\|\hat{s}\|} = \frac{\|G^+ n\|}{\|G^+ d\|} \leq \frac{\lambda_1}{\lambda_T} \frac{\|n\|}{\|d\|} = C$$

推定誤差

誤差の上限

SNRと誤差の上限  
がわかる!  $\lambda_T \Sigma$

$$\sum_{k=1}^T \frac{\sigma^2}{\lambda_k^2}$$

Perturbation error

$$\sum_{k=T+1}^R \frac{\alpha^2}{\lambda_k^2}$$

Regularization error

(誤差による問題) 選択  
= エルム(2種類の中間に位置)

誤差2

## Tikhonov Regularization

$$\min. ( \| \mathbf{d} - \mathbf{G} \mathbf{s} \|^2, \| \mathbf{s} \|^2 )$$



$$\min. J(\mathbf{s}) = \| \mathbf{d} - \mathbf{G} \mathbf{s} \|^2 + \alpha \| \mathbf{s} \|^2$$



$$(\mathbf{G}^T \mathbf{G} + \alpha^2 \mathbf{I}) \mathbf{s} = \mathbf{d}^T \mathbf{s}$$

SVD,  $\mathbf{G} = \mathbf{V} \Lambda \mathbf{U}^T$  (SVD) とある。

$$\begin{aligned} \mathbf{G}^T \mathbf{G} + \alpha^2 \mathbf{I} &= (\mathbf{V} \Lambda \mathbf{U}^T)^T (\mathbf{V} \Lambda \mathbf{U}^T) + \alpha^2 \mathbf{U} \mathbf{U}^T \\ &= \mathbf{U} \Lambda^T \Lambda \mathbf{U} + \alpha^2 \mathbf{U} \mathbf{U}^T \end{aligned}$$

$$= \mathbf{U} \left[ \begin{array}{cccc} \lambda_1^2 + \alpha^2 & & & \\ & \ddots & & \\ & & \lambda_n^2 + \alpha^2 & \end{array} \right] \mathbf{U}^T$$

右角成部分  $\propto \alpha^2$  がもつていて

→ 特異値  $\lambda_k \in \mathbb{R}$  をみて

### (III) Tikhonov の逆行法

$$G_\alpha^+ = (G^T G + \alpha I^2)^{-1} G^T$$

$$= \left( \sum_{k=1}^n (\lambda_k^2 + \alpha^2) u_k u_k^T \right)^{-1} \sum_{k=1}^R \lambda_k u_k u_k^T$$

$$= \sum_{k=1}^R \frac{\lambda_k^2}{\lambda_k^2 + \alpha^2} \frac{u_k}{\lambda_k} v_k^T$$


### (IV) TSVD. と Tikhonov の違い

#### TSVD

$$G_T^+ = \sum_{k=1}^R \frac{1}{\lambda_k} u_k v_k^T = \sum_{k=1}^R \frac{f_k}{\lambda_k} \frac{1}{\lambda_k} u_k v_k^T$$

#### Tikhonov

$$G_\alpha^+ = \sum_{k=1}^R \frac{\frac{\lambda_k^2}{\lambda_k^2 + \alpha^2}}{\lambda_k} \frac{1}{\lambda_k} u_k v_k^T$$



正則化法3

### (4) 約束条件付き LS

$$\min. |s|^2$$

$$\text{s.t. } \|dl - Gs\|^2 = \sigma^2$$

τ / イズレベルムルハスス

$$L(s, d) = |s|^2 + \frac{1}{\alpha^2} (|dl - Gs|^2 - \sigma^2)$$

↓

$$\hat{s} = (G^T G + \alpha^2 I)^{-1} G^T d$$

Tikhonov ループ

$$\|dl - G(G^T G + \alpha^2 I)^{-1} G^T d\|^2 = \sigma^2$$

$\alpha^2$  の決定方法.

正則化法4

止まります

## III L1/L2 最小化

$$\min J(s) = \|d - Gs\|^2 + \alpha^2 |s|,$$

$$s = s^+ - s^- \quad (s^+ \geq 0, \quad s^- \geq 0)$$

を解く。

$$\begin{aligned} J(s^+, s^-) &= \|Gs\|^2 - 2d^T Gs + \|d\|^2 \\ &\quad + \lambda^2 \mathbf{1}_n^T s^+ + \lambda^2 \mathbf{1}_n^T s^- \\ (\mathbf{1}_n &= (1, \dots, 1)^T \in \mathbb{R}^n) \end{aligned}$$

を解く。

$$y = \begin{pmatrix} s \\ s^+ \\ s^- \end{pmatrix} \in \mathbb{R}^{3n}$$

を解く。

$$J(y) = y^T H y + h^T y$$

$$H = \begin{pmatrix} G^T G & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}, \quad h = \begin{pmatrix} -2G^T d \\ \lambda^2 \mathbf{1}_n \\ \lambda^2 \mathbf{1}_n \end{pmatrix} \in \mathbb{R}^{3n}$$

△形式、拘束条件  $S = S^+ - S^-$

$$\Leftrightarrow \begin{pmatrix} y_1 \\ \vdots \\ y_m \end{pmatrix} = \begin{pmatrix} y_{m+1} \\ \vdots \\ y_{2m} \end{pmatrix} - \begin{pmatrix} y_{2m+1} \\ \vdots \\ y_{3m} \end{pmatrix}$$

$$y_j \geq 0 \quad (j = m+1, \dots, 3m)$$

かつ  $\geq 2^n$  解 (T12) が少い。 (二次計画問題)

正則化法

(1) Total Variation

値が変化可  $\Rightarrow$   $\alpha$  稀 = 微分のスハ  $- \lambda$

$$\min, J(s) = \|d - Gs\|^2 + \alpha^2 \|Ds\|_1$$

$$D = \begin{pmatrix} -1 & 1 & 0 & \cdots & 0 \\ 0 & -1 & 1 & \cdots & 0 \\ \vdots & & & \ddots & \\ 0 & \cdots & \cdots & 0 & -1 \end{pmatrix}$$

最大推定法

## ⑪ 正則化と統計的視点で入力予測. ①

$$d = Gs + in$$

ただし、 $s, in$  は独立な確率変数.

$$p(s, in) = p_1(s) p_2(in)$$

$d$  の pdf は、独立な確率変数の和の分布と呼ぶ  
convolution

$$p(d) = \int p_1(s') p_2(d - Gs') ds'$$

\$s \rightarrow s' \rightarrow d\$ に  
 \$T\_1 \oplus T\_2 \rightarrow T\_1 \oplus T\_2 \oplus T\_3\$ に  
 \$G \rightarrow G\_1 \oplus G\_2 \oplus G\_3\$ に  
 \$\times\$ が付く

であるが、 $s$  を固定した条件で計算する。

$$p(d|s) = \int \delta(s' - s) p_2(d - Gs') ds'$$

$$= p_2(d - Gs)$$

つまり、 $in$  が多次元 Gaussian (\$\rightarrow\$ 従う  $in \sim N(0, \Sigma)$ )

とき

$$p(d|s) = \frac{1}{(2\pi \det \Sigma)^{\frac{N}{2}}} \exp \left( -(d - Gs)^T \Sigma^{-1} (d - Gs) \right)$$



likelihood function (似合)

→ タイプ得点 ML.

$$\max. p(\mathbf{d} | \mathbf{s})$$

$$\min. (\mathbf{d} - \mathbf{G}\mathbf{s})^\top \Sigma^{-1} (\mathbf{d} - \mathbf{G}\mathbf{s})$$

特徴 12.  $\Sigma = \sigma^2 I$  のとき

$$\min. (\mathbf{d} - \mathbf{G}\mathbf{s})^\top (\mathbf{d} - \mathbf{G}\mathbf{s})$$

(Least-square)

MAP推定 = 正則化

③ 統計的視点 ②

$S \rightarrow$  データが  $\mathbf{d}$  になる確率  $p(\mathbf{d} | \mathbf{s})$

(likelihood)

→ づけ.

$\mathbf{d} \rightarrow$   $s$  が原因である確率  $p(s | \mathbf{d})$

( $\sim p_{\text{posteriori}}$ )

( $\alpha$  position)

を最大化

$$p(s | d) = \frac{p(d | s) p(s)}{p(d)}$$

$$\sim \underbrace{p(d | s) p(s)}_{\rightarrow \max}$$


観測値も  $s$  もガウス分布に従う場合

$$p(s) \propto e^{-\frac{1}{2\sigma_s^2} s^T s}$$

$$p(d | s) \propto e^{-\frac{1}{2\sigma_d^2} (d - Gs)^T (d - Gs)}$$

よし、事後確率

$$p(d | s) p(s) \propto \underbrace{e^{-\frac{1}{2\sigma_d^2} (d - Gs)^T (d - Gs)}}_{\downarrow} \underbrace{e^{-\frac{1}{2\sigma_s^2} s^T s}}$$



$$\min_s \frac{1}{2\sigma^2} (\mathbf{d} - \mathbf{G}s)^T (\mathbf{d} - \mathbf{G}s) + \frac{1}{2\sigma_s^2} s^T s$$

$$\hat{s} = (\mathbf{G}^T \mathbf{G} + \frac{\sigma^2}{\sigma_s^2} \mathbf{I})^{-1} \mathbf{G}^T \mathbf{d}$$

## ⑩ 正則化パラメータの選択法

• L-Curve 法

Tikhonov 正則化解

$$\hat{s}_\alpha = (\mathbf{G}^T \mathbf{G} + \alpha^2 \mathbf{I})^{-1} \mathbf{G}^T \mathbf{d}$$

$$= \sum_{k=1}^R \frac{\lambda_k d_k}{\lambda_k^2 + \alpha^2} u_k \quad (d_k = v_k^T \mathbf{d})$$

$$|\hat{s}_\alpha|^2 = \sum_{k=1}^R \left( \frac{\lambda_k d_k}{\lambda_k^2 + \alpha^2} \right)^2$$

$$|\mathbf{d} - \mathbf{G}\hat{s}_\alpha|^2 = \left| \sum_{k=1}^N d_k v_k - \sum_{k=1}^R \frac{\lambda_k^2 d_k}{\lambda_k^2 + \alpha^2} v_k \right|^2$$

$$= \left| \sum_{k=1}^N \frac{\alpha^2 d_k}{\lambda_k^2 + \alpha^2} v_k \right|^2$$


( $v_k = 0$  かつ  $\lambda_k = 0$ )

$$= \sum_{k=1}^N \left( \frac{\alpha^2 d_k}{\lambda_k^2 + \alpha^2} \right)^2$$

$\approx 2'$ , 次元を合わせるために =

$$\begin{cases} P = |d - G \hat{s}_\alpha|^2 \\ \eta = \lambda_1^2 |\hat{s}_\alpha|^2 \end{cases}$$

とおいて、 $\alpha$ を決める =  $(P, \eta)$  の直か  
定まる。  $\approx 2'$ ,  $(P, \eta)$  平面上に  $\alpha$  を変化  
させながら、点をプロットしていく。



$$\frac{\partial \eta}{\partial \alpha^2} = -\lambda_1^2 \sum_{k=1}^R \frac{2\lambda_k^2 d_k^2}{(\lambda_k^2 + \alpha^2)^3}$$

$$\frac{\partial \rho}{\partial \alpha^2} = \dots = -\frac{\partial \eta}{\partial \alpha^2} \frac{\alpha^2}{\lambda_1^2}$$

$$\left\{ \begin{array}{l} \frac{\partial \eta}{\partial \rho} = -\frac{\lambda_1^2}{\alpha^2} \end{array} \right.$$