

⑩ Generalized Cross Validation (GCV法)

$$\text{観測方程式 } \mathbf{d} = \mathbf{G} \mathbf{s} + \mathbf{n}$$

\Leftrightarrow 対し、第 k 成分を取り除いた方程式

$$\mathbf{d}^k = \mathbf{G}_k \mathbf{s} + \mathbf{n}^k$$

$$\in \mathbb{R}^{N-1} \quad \mathbf{G} \in \mathbb{R}^{(N-1) \times M}$$

を考えよ。

Tikhonov 正則化解は

$$\hat{\mathbf{s}}_\alpha^k = \mathbf{G}_\alpha^{+k} \mathbf{d}^k$$

$$= ((\mathbf{G}^k)^T \mathbf{G}^k + \alpha^2 \mathbf{I})^{-1} (\mathbf{G}^k)^T$$

となる。この中 \mathbf{G} は作用させた第 k 成分

$$(\mathbf{G} \mathbf{s}_\alpha^k)_k$$

$$\in \mathbb{R}^N$$

は、第 k 成分を除いて得られる \mathbf{s}_α^k の解である。

予測されるデータの第 k 成分を出力。

$\vec{z} = \vec{z}'$

$$d\ell = \begin{pmatrix} d_1 \\ \vdots \\ d_k \\ \vdots \\ d_N \end{pmatrix}$$

$$J(\alpha) = \frac{1}{N} \sum_{k=1}^N \left(\underbrace{d_k - (G \hat{s}_\alpha^k)_k}_{\text{を最小化する } \alpha \text{ を正則化パラメータとする.}} \right)^2$$

$T = T^{\dagger}$ し、この T^{\dagger} と G^{+k} を $k = 1 \dots N$ ($=$ おなじ) 計算する必要がある。

$\vec{z} = \vec{z}'$.

$$J(\alpha) \simeq \frac{\frac{1}{N} \| d\ell - G \hat{s}_\alpha \| {}^2}{\left(\frac{1}{N} \operatorname{Tr}(I - GG_\alpha^+) \right)^2}$$

と近似し、 G_α^+ の計算を (ある α (= 表示)) (回 $T = T^{\dagger}$ 済みの方法で GCV を計算する)。

⑪ One-leave-out Lemma

$$\tilde{\vec{y}} = \begin{pmatrix} d_1 \\ \vdots \\ d_{k-1} \\ \vdots \\ d_N \end{pmatrix}$$

第 k 成分 d_k が削除された \vec{y}

$$\hat{d} = \begin{pmatrix} (G\hat{s}_\alpha^k)_k \\ d_{k+1} \\ \vdots \\ d_N \end{pmatrix}$$

$$L^2 \text{ 误差 } \hat{s}_\alpha^k = G_\alpha^+ \tilde{d}$$

∴

$$\hat{s}_\alpha^k = \underset{s}{\operatorname{argmin}} \left\{ \| \tilde{d} - G^k s \|^2 + \alpha^2 \| s \|^2 \right\}$$

\mathbb{R}^{n-1}

第 k 步解 $s \in \mathbb{R}^{n-1}$

②

$$= \underset{s}{\operatorname{argmin}} \left\{ \| \tilde{d} - G s \|^2 + \alpha^2 \| s \|^2 \right\}$$

第 k 步解 $(G\hat{s}_\alpha^k)_k$

$s = \hat{s}_\alpha^k (= \hat{s}_\alpha^k \cup 0)$

第 k 步解 $(G\hat{s}_\alpha^k)_k$

解 $(\hat{s}_\alpha^k \cup 0) = \hat{s}_\alpha^k$ 等式 ② 成立？

$L^2 = \hat{s}_\alpha^k, 2$

$$\hat{s}_\alpha^k = G^+ \tilde{d}$$



Cross Validation の評価関数 $\rho(s, G_\alpha^k, \hat{s}_\alpha^k)$ は?

$$J(\alpha) = \frac{1}{N} \sum_{k=1}^N \| d_k - (G \hat{s}_\alpha^k)_k \|^2$$

$\bar{z} = z'$

$$\begin{aligned}
 & \frac{\left(\begin{array}{c} \text{K} \in \text{除以} T = \text{正規} \\ \text{予測誤差} \end{array} \right)}{\left(\begin{array}{c} \text{K} \in \text{除以} T = \text{正規} \\ \text{予測誤差} \end{array} \right)} = \frac{d_k - (G \hat{s}_\alpha^k)_k}{d_k - (G \hat{s}_\alpha^k)_k} \\
 & = \frac{d_k - \tilde{d}_k + \tilde{d}_k - (G \hat{s}_\alpha^k)_k}{d_k - \tilde{d}_k} \\
 & = 1 + \frac{\tilde{d}_k - (G \hat{s}_\alpha^k)_k}{d_k - \tilde{d}_k} \\
 & = 1 + \frac{(G \hat{s}_\alpha^k)_k - (G \hat{s}_\alpha)_k}{d_k - \tilde{d}_k} \\
 & = 1 + \frac{(G G_\alpha^+ \tilde{d})_k - (G G_\alpha^+ d)_k}{d_k - \tilde{d}_k}
 \end{aligned}$$

$(\langle d_i \rangle, \langle d_i \rangle_1)$

$$= 1 + \frac{\left(G G_{\alpha}^+ \begin{pmatrix} d_k \\ d_k \\ d_k \\ d_N \end{pmatrix} - \begin{pmatrix} d_k \\ d_k \\ i \\ d_N \end{pmatrix} \right)_k}{d_k - \tilde{d}_k}$$

$$= 1 + \frac{\left(G G_{\alpha}^+ \begin{pmatrix} 0 \\ \vdots \\ 0 \\ \tilde{d}_k - d_k \\ 0 \\ \vdots \\ 0 \end{pmatrix} \right)_k}{d_k - \tilde{d}_k}$$

$$= 1 + \frac{(G G_{\alpha}^+)_k (\tilde{d}_k - d_k)}{d_k - \tilde{d}_k}$$

$$= 1 - (G G_{\alpha}^+)_k$$

±, 2.

$$d_k - (G \hat{s}_{\alpha})_k = \frac{d_k - (G \hat{s}_{\alpha})_k}{1 - (G G_{\alpha}^+)_k}$$

ETFY, LT=0¹¹, 2.

$$J(\alpha) = \frac{1}{N} \sum_{k=1}^N \frac{(d_k - (G \hat{s}_{\alpha})_k)^2}{(1 - (G G_{\alpha}^+)_k)^2}$$

K=1~N の $\frac{1}{N} \sum_{k=1}^N$

$$\sim \frac{1}{N} \sum_{k=1}^N \frac{(d_k - (G \hat{s}_{\alpha})_k)^2}{(1 - (G \hat{s}_{\alpha})_k)^2}$$

$$= \frac{\frac{1}{N} \sum_{k=1}^N \left(\frac{1}{N} \sum_{j=1}^n (I - G G_\alpha^\dagger)_{kj} \right)^2}{\left(\frac{1}{N} \text{Tr}(I - G G_\alpha^\dagger) \right)^2}$$

□

結果、Tikhonov 正則化解 \hat{s}_α の自乗誤差 $\| d - G \hat{s}_\alpha \|^2$
 を $\left(\text{Tr}(I - G G_\alpha^\dagger) \right)^2$ で補正して才是最小化する
 が、(近似的) (=) Cross Validation 誤差を最小化
 する正則化パラメータ α である。


④ S-curve 法

L1/L2 \hookrightarrow 最小化


$$\min. \| d - G s \|^2 + \alpha^2 \| s \|_1$$

の α を 決定す。

s_α の収束過程



S 曲線



幅広い区間の α は $\pm \infty$ で

非零成分数やあまり変化しない領域
この区間から α を選ぶ。

③ 非線形解法の基礎

$$d(x) = \int s(x') g(x-x') dx' + n(x)$$

$y - x$ $s(x)$ を パラメタ ω で表す

$$\Rightarrow s = \begin{pmatrix} s_1 \\ \vdots \\ s_M \end{pmatrix}$$
 を未知数とし、

評価関数

$$J(s) = \| d - g(s) \|^2$$

を非線形最適化により、最小化。

(例)

$$s(x) = \sum_{k=1}^M \tilde{q}_k \tilde{s}(x-x_m)$$

\tilde{q}_k $\tilde{s}(x-x_m)$
 点 x 強度 位置

このときは、

$$d(x) = \sum_{k=1}^M g_k \underbrace{g(x - x_m)}_{\uparrow}$$

g が非線形で x_m の既知点と $g(x - x_m)$ は $T = T$ である

したがって、 x_m が未知点と非線形、 $T = T$ である

④ 最急降下法

$$s_{j+1} = s_j - \alpha_j \nabla J(s_j)$$

更新幅 α は、

$$\min. J(\alpha_j) = J(s_j - \alpha \nabla J(s_j))$$

で決める。(Curry の規則)



$$\frac{\partial}{\partial \alpha} J(s_j - \alpha \nabla J(s_j)) = \nabla J(s_j - \alpha \nabla J(s_j)) \cdot (-\nabla J(s_j)) = 0$$

$$\Leftrightarrow \underbrace{\nabla J(s_{j+1}) \cdot \nabla J(s_j)}_{} = 0$$

すなはち、探索方向は、前回と直交する

です！

(シグマ)

$$g(s) = G s - z$$


$$J(s) = \|d - Gs\|^2$$

$$= (0\text{次}) + (1\text{次}) + s^T \boxed{G^T G} s$$

牛頓法の式
かっこで囲む

$J = \text{一定}$ G の条件を満たすとき、

$J(s)$ 等高線は平行となる



③ Gauss - Newton 法

$g(s) \in S_j$ まわりで Taylor 展開。

$$g(s) \approx g(s_j) + \underbrace{\left(\frac{\partial g}{\partial s} \right)^T}_{\equiv \nabla g(s_j)} (s - s_j) + \underbrace{\frac{\partial^2 g}{\partial s \partial s^T}}_{\text{Hessian } H = (3 \times 3 \cdots \times n) H} (s - s_j) (s - s_j)$$

$$G = \begin{pmatrix} \frac{\partial g_1}{\partial s_1} & \cdots & \frac{\partial g_N}{\partial s_1} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_1}{\partial s_M} & \cdots & \frac{\partial g_N}{\partial s_M} \end{pmatrix}^T = \begin{pmatrix} \frac{\partial g_1}{\partial s_1} & \cdots & \frac{\partial g_1}{\partial s_M} \\ \vdots & \ddots & \vdots \\ \frac{\partial g_N}{\partial s_1} & \cdots & \frac{\partial g_N}{\partial s_M} \end{pmatrix}$$

レ2. 評価関数(=入力)

$$J(s) = \| d - g(s_j) - G(s-s_j) - H x_1(s-s_j) x_2(s-s_j) \|^2$$

$$\begin{aligned}
 &= (\text{0次項}) - (s-s_j)^T G^T (d - g(s_j)) + \underbrace{(s-s_j)^T G^T G (s-s_j)}_{\text{②}} \\
 &\quad - \underbrace{2(d - g(s_j)) \cdot (H x_1(s-s_j) x_2(s-s_j))}_{\text{①}} + \text{(高次項)} \\
 &\quad \downarrow \text{予測誤差} \| d - g(s_j) \| \text{ (2+3+4)} \\
 &\quad \leftarrow \text{②} \text{ (対称性)} \text{ ①} / 2 \text{ で}
 \end{aligned}$$

$$\begin{aligned}
 &\simeq (\text{0次項}) - (s-s_j)^T G^T (d - g(s_j)) + (s-s_j)^T G^T G (s-s_j) \\
 &\quad \downarrow \min.
 \end{aligned}$$

$$s - s_j = (G^T G)^{-1} G^T (d - g(s_j))$$

よし

$$\underbrace{s_{j+1}}_{s_j + (G^T G)^{-1} G^T (d - g(s_j))} = s_j + (G^T G)^{-1} G^T (d - g(s_j))$$

- ヤコビア $G = \left(\frac{\partial g}{\partial s}\right)^T$ の条件から G は正則 \rightarrow 正則化

$$s_{j+1} = s_j + (G^T G + \alpha^2 I)^{-1} G^T (d - g(s_j))$$

Levenberg - Marquadt 法

α^2 小さい \rightarrow Newton 法 収束遅い

α^2 大きい \rightarrow 最急降下法 収束速い



収束解を \hat{s}^* とし、 s_a までは z^2 ,

$$d = G(s - \hat{s}^*) + n \quad (G = \left(\frac{\partial g}{\partial s}\right)^T(\hat{s}^*))$$

と展開できます

$$n \sim N(0, \sigma^2 I)$$

と仮定する。このとき 干渉定誤差(分散)は、

$$E[(s - \hat{s}^*)(s - \hat{s}^*)^T] = \sigma^2(G^T G)^{-1}$$

となります。

σ^2 が未知な場合は

$$\hat{\sigma}^2 = \frac{1}{N-M} \| d - g(\hat{s}^*) \|^2$$

(= 約得した干渉定値を用いて)

・ ポジティブの条件が悪い

$\rightarrow \left(\frac{\partial g}{\partial s}\right)^T$ の外の干渉定値をもつ

