

⑩ Blind deconvolution

$$d = \underbrace{G}_{\downarrow \text{未知}} \underbrace{s}_{\downarrow \text{未知}} + n$$

のとき、 s ($\in G$) を推定する

- 基底 ($G = (g_1, \dots, g_m)$) (= 仮定を入力)
- 信号 s (= 仮定を入力)

⑪ 基底 $G = (g_1, \dots, g_m)$ (= 仮定を入力) の方法

- 主成分分析 (Principal Component Analysis)

データ列 $\{d_i\}$ を正規直交基底 $\{v_k\}$ で分解する。

$$\begin{aligned} d_i &= \sum_{k=1}^n s_k v_k = (\underbrace{v_1, \dots, v_n}_G) \begin{pmatrix} s_1 \\ \vdots \\ s_n \end{pmatrix} \\ &\in \mathbb{R}^n \\ &= \sum_{k=1}^n (v_k^T d_i) v_k \end{aligned}$$

データの自乗誤差が最小となるように。

$$J(\{v_k\}) = E \left[\|d_i - \sum_{k=1}^n s_k v_k\|^2 \right] + \lambda (1 - v_k^T v_k)$$

→ min

$$= E \left[\| d - \sum_{k=1}^n (\hat{w}_k^\top d) \hat{w}_k \|^2 \right] + \lambda (1 - \hat{w}_k^\top \hat{w}_k)$$

$$= E \left[\| d \|^2 \right] - 2E \left[\sum_{k=1}^n (\hat{w}_k^\top d)^2 \right] + E \left[\sum_{k=1}^n (\hat{w}_k^\top d)^2 \right] + \lambda (1 - \hat{w}_k^\top \hat{w}_k)$$

$$= E \left[\| d \|^2 \right] - E \left[\sum_{k=1}^n (\hat{w}_k^\top d)^2 \right] + \lambda (1 - \hat{w}_k^\top \hat{w}_k)$$

極値条件は、

$$\frac{\partial J}{\partial \hat{w}_k} = -2 \underbrace{E[d d^\top]}_{R} \hat{w}_k - 2\lambda \hat{w}_k = 0$$

\Rightarrow d と \hat{w}_k が平行 (= 共分離可能?)

R

$$\Leftrightarrow R \hat{w}_k = -\lambda \hat{w}_k$$

よって、R の固有ベクトル $\{ \hat{w}_k \}$ を λ で割れば
 $\hat{w}_k \in \text{Null}(P)$ が得られる

④ PCA の ICA との関係

$n = N$ のとき

$$dI = V S$$

" "

$$(v_1 \dots v_N)$$

$$\hat{S} = V^{-1} dI = V^T dI$$

ここで \hat{S} 、共分散行列を考へる

$$\begin{aligned} E[\hat{S} \hat{S}^T] &= E[V^T dI dI^T V] \\ &= V^T R V \\ &= V^T V \Lambda^2 V^T V \\ &= \Lambda^2 \end{aligned}$$

つまり、PCA は必ず得られる \hat{S} の各成分は無相関 である。

⑤ スパース ユーティング

... たゞべく少數個の基底でデータを分解してみる

場合: convex

$$J(g_k, s_k) = \underbrace{E\left[\|d - \sum_{k=1}^n s_k g_k\|^2\right]}_q + \lambda^2 \underbrace{\sum_{k=1}^n \log\left(1 + \frac{s_k^2}{\sigma^2}\right)}_{\substack{\rightarrow \text{解を求めるため} \\ \text{正則化項}}}$$

$$\left(s_k^2 \ll \sigma^2 \Rightarrow \log\left(1 + \frac{s_k^2}{\sigma^2}\right) \approx 0\right)$$

(1) まず、 $\{g_k\}$ を固定して、 J を最大化する $\{s_k\}$ を
非線形最適化で求める

(2) $\{s_k\}$ を固定して、最急降下方向で g_k を更新する

$$g_k^{(j+1)} = g_k^{(j)} - c \frac{\partial J(g_k^{(j)})}{\partial g_k}$$

④ 信号 s の仮定入力方法

- 独立成分分析 (Independent Component Analysis)

瞬時混音.

$$\begin{pmatrix} d_1(t) \\ d_2(t) \end{pmatrix} = (g_1 \ g_2) \begin{pmatrix} s_1(t) \\ s_2(t) \end{pmatrix}$$

の blind deconvolution を考える (1つ会場の話者分離
T2E1用意)

仮定

• $s_1(t) \in s_2(t)$ は独立である

• $E[ss^T] = I$

$$dl = \begin{pmatrix} \frac{s_1}{c_1} & \frac{s_2}{c_1} \end{pmatrix} \begin{pmatrix} c_1 s_1(t) \\ c_2 s_2(t) \end{pmatrix}$$

といふ分解を c_1, c_2 で

決まるなら s_1, s_2 の分散は 1 であると仮定する

④ テータの白色化 (whitening)

$$dl = G s \quad (= \text{左} \times \text{右} \times W)$$

左から \times

$$f = W dl = W G s$$

が白色信号 ($E[ff^T] = I$) となる $= \exists$.

$$E[ff^T] = W E[dl dl^T] W^T$$

$$= W R W^T$$

$$= W V \Lambda^2 V^T W^T$$

$$\left. \begin{aligned} G &= V \Lambda V^T : \text{未知 } T = ? \\ R &= E[dl dl^T] = V \Lambda^2 V^T \text{ とする.} \\ \Rightarrow & dl \text{ が } V \text{ で得す.} \end{aligned} \right)$$

となる。 $W = \Lambda^T V^T$ とすれば、 $E[ff^T] = I$ となる

このとき

$$\begin{aligned} f &= WG\$ \\ &= \Lambda^T V^T V \Lambda U^T \$ \\ &= U^T \$ \end{aligned}$$

となる。すなはち、白色化したデータ f の blind deconvolution
には、基底を並べて U^T は直交行列である。

尖度最大化

$$J(\{w_j\}) = \left| E[(w^T f)^4] - 3 \right| + \lambda (1 - w^T w)$$

$$= (\text{sgn kurt}(w^T f)) (E[(w^T f)^4] - 3)$$

$$\rightarrow \lambda (1 - w^T w)$$